# ECOCO BATE BY A BY A BOOME CONTROLL CON

ањжњой вхањм

#### Otvoreno računarstvo

XML

- Uvod
- Pravila XML-a
- Primjene XML-a
- Prostori imena

Mario Žagar



### Problem podataka



- Operacije nad podacima (Open Information Management):
  - Interpretacija
  - Prezentacija
  - Interoperabilnost
  - Prenosivost
  - Pretraživanje





```
<b>00364244545 Marko Ferković - Enter</b><br><i>>Student</i><br>< Sveučilište u Zagebu<br><u>Fakultet elektrotehnike i računarstva</u>
Unska 3<br><br/>HR-10000 ZAGREB<br>
```

- HTML definira:
  - konačan broj oznaka i njihovu semantiku
  - strukturu podataka unutar dokumenta
    - oznake i struktura prilagođene su domeni prikaza podataka
- Jezik prilagođen autorima i korisnicima (ljudima)
- Računala služe samo za objavljivanje i prikaz, nema obrade!

### Ograničenja HTML-a:



- Ne postoji čvrsta, formalna struktura dokumenta koje se autor mora držati, a koja bi omogućila verifikaciju
- Preglednici nastoje sami popraviti pogreške programera
  - jednostavnost stvaranja stranica plaćena složenošću pripreme prikaza
- Ne postoji fleksibilnost za opis podataka iz različitih domena:
  - proširivost oznaka kao mehanizma uvođenja novih pojmova
  - prilagodljivost strukture opisivanim podacima
- Problem uočen pojavom prvih strojnih "korisnika" web stranica
  - tumačenje značenja podataka na web stranici čovjeku jednostavno, računalu vrlo teško (common sense je za današnju UI nedostižan cilj)

#### SGML



- Sveobuhvatan, složen standard za opis tipova dokumenata
- Vrlo opširan, velik broj neobaveznih elemenata
  - cijena implementacije
  - problemi u kompatibilnosti različitih implementacija
- HTML je tip dokumenta definiran SGML-om
- Za široku uporabu potrebna jednostavnija inačica SGML-a
  - jednostavna, učinkovita i prenosiva implementacija za što veći broj platformi i programskih jezika
  - mali, ali čvrsti skup pravila, podrška internacionalizaciji

### XML - eXtensible Markup Language



- Mlađi (i manji) brat SGML-a
  - Primjena u opisu, pohrani i razmjeni različitih podataka u tekstualnom obliku zapisa
- Nema predefiniranih oznaka
  - Definiraju se po potrebi
- Formalan i sažet oblik
  - Mali broj jednostavnih, ali strogih pravila
- Jednostavnost obrade
  - Uvjetuje veće zahtijeve pri rukovanju sa sadržajem dokumenta (suprotno u odnosu na HTML)
- Orijentiran prema strojnoj obradi

#### Svojstva XML-a



- Proširivost:
  - oznake se definiraju po potrebi
- Odjeljivanje podataka od prezentacije:
  - oznake opisuju podatake, ne njihov izgled
- Validacija:
  - stroga pravila strojna provjera valjanosti i strukture
- Internacionalizacija:
  - XML izvorno koristi Unicode (UTF-8)
- Prenosivost:
  - XML dokument je obična tekst datoteka
- Rasprostranjenost:
  - neovisan o platformi i podržan od većine prog. jezika



### Primjer XML dokumenta:

```
<?xml version="1.0" encoding="UTF-8" ?>
<student jmbag="00364244545">
  <ime>Marko</ime>
  Ferković - Enter
  <institucija>
      <sveučilište>Sveučilište u Zagrebu</sveučilište>
      <fakultet id="0036">
         <ime>Fakultet elektrotehnike i računarstva</ime>
        <adresa>
           <ulica>Unska</ulica>
           <broj>3</broj>
           <pbr>HR-10000</pbr>
           <grad>Zagreb</grad>
        </adresa>
      </fakultet>
  </institucija>
</student>
```

### XML i strukturiranje podataka

- XML ne propisuje oznake, već pravila definiranja
  - da li je XML meta-jezik?
- Korisnici dokumenta XML tumače značenje oznaka
  - što npr. znači oznaka <ime> ?
  - koje su sve oznake potrebne za opis podataka?
- Oznake definiraju hijerarhijske odnose podataka unutar dokumenta (odnos roditelj – dijete):

### XML i opis podataka



- Jezik za opis podataka:
  - konačan broj oznaka (rječnik)
  - struktura podataka (tvorba rečenica)
  - semantika (značenje riječi)
- Konačan broj oznaka i struktura
  - određuju se tipom dokumenta,
  - tipovi se definiraju jezicima DTD ili XML Schema
- Semantika pojedinih oznaka definirana implicitno
  - mora biti dijeljena između svih entiteta koji koriste pojedini tip dokumenta (shared semantics)
- Eksplicitna definicija semantike semantički web

### XML i opis podataka



- Standardizacija jezika po domenama primjene
  - horizontalne domene
    - razmjena podataka između aplikacija u istoj domeni (npr. CAD sustavi, zdravstvo, e-business, logistika ...)
    - onemogućuje tzv. vendor-locking
  - vertikalne domene
    - opis podataka prisutnih u svim domenama ili neovisnih o domenama primjene (npr. stylesheets, SOAP ...)
  - razmjena podataka između različitih domena
    - npr. između zdravstva, osiguranja, MUP-a, biračkih popisa ...

## Povijest XML-a



- HTML beznadno izgubio prvobitnu namjenu
  - odvajanja prikaza od sadržaja, više narječja HTML-a (Netscape, Microsoft ...)
- Kasne 90-te
  - Bosak, Bray, Clark i drugi prijedlog XML-a
- 1998-02-10 W3C preporuka, verzija 1.0
- Eksplozija tehnologija i primjena XML-a
- Aktualno:
  - četvrto izdanje XML preporuke iz kolovoza 2006.
  - postoji i XML 1.1! (nije u širokoj upotrebi)

### Svijet XML-a



- Prateći jezici (preporuke i norme):
  - DTD, XML Schema, XSL, XSLT, XPath, XQuery, DOM, SAX, Namespaces, XLink, XPointer, ...
  - XHTML, WAP, ...
  - ODF, SMIL, SVG,CML, MathML, MusicML, OTA, ebXML, ...
  - XML-RPC, SOAP, WSDL, ...

## Pravila XML-a

## XML - primjer sadržaja dokumenta



procesna naredba
komentar
element korijen (root)
element dijete (child)
prazan element
atribut

```
<?xml version=1.0"?>
<!-- komentar -->
<radnik>
  <ime> Marko </ime>
  o
  <place><place</pre><place</place>
</radnik>
```

#### Element



```
<ime_elementa> sadržaj </ime_elementa>
```

- Element osnovna gradivna komponenta XML dokumenta, sastoji se od:
  - početne oznake (<ime\_elementa>),
  - završne oznake (</ime\_elementa>) i
  - sadržaja omeđenog oznakama.
- Elementi se imenuju po entitetima domene čiji se podaci opisuju npr.:
  - jmbag, ime, prezime, predmet, ocjena...
    - iz domene poslovnih procesa na sveučilištu
- Imena elemenata su case-sensitive:
  - <jmbag> ≠ <JMBAG>

### Imenovanje elementa



Valjana imena elementa:

```
[slova][_], [0-9][slova][znakovi]*
```

- Razmak se ne smije koristiti u tvorbi imena
- Ime elementa ne smije započeti s xml
  - u imenu se može koristiti većina Unicode znakova
- Prvi znak imena odmah nakon oznake "<"</li>
- Primjeri dobro oblikovanih imena elemenata:

```
<jmbag>, <first_name>, <first-name>, <šifra>, <_note>, <mbr >, <velika.seoba.naroda>, <صغث>
```

primjeri krivih imena elemenata:

### Sadržaj elementa



- Sadržaj elementa:
  - sve između početne i završne oznake
- Vrste sadržaja:
  - prazan
  - jednostavan
  - elementi djeca
  - miješani

#### Prazan sadržaj



```
<ime_elementa></ime_elementa>
<ime_elementa/>
```

- Element nema sadržaja
- Moguće koristiti standardan ili skraćen način zapisa praznog elementa

### Jednostavan sadržaj



- Podrazumijeva samo tekst
  - bez oznaka ili specijalnih karaktera
- Obrađuje se od strane parsera
  - ne smije sadržavati znakove od značenja za parser (početak oznake, entiteta ...)
- Posebni znakovi:

```
<, >, &, "i', moraju/mogu se nadomjestiti entitetima &It;, &gt;, &amp;, &quot; i &apos;
```

#### Elementi djeca



- Sadržaj
  - unutar elementa ugnježđeni isključivo jedan ili više podelemenata (čije vrste sadržaja također mogu biti ...)
- Očuvanje redosljeda otvaranja i zatvaranja elemenata
   <element1><element2></element1></element2></element2>





```
Predavanje će obraditi kvantitativnu metodu
verfikacije homogenosti XML dokumenta
u prisustvu ionizirajućeg zračenja, a koju su
razvili
<name>Cholsky</name> i <name>Rangapathra<name> sa
sveučilišta <institution>UC Berkeley</institution>.
</content>
```

- Sadržaj se sastoji od teksta i elemenata u bilo kojem redoslijedu
- Za elemente unutar miješanog sadržaja vrijede ista pravila kao i za ostale elemente

#### Atributi



- Atribut mora pripadati elementu
- Element može imati jedan ili više atributa
- Atribut čini uređeni par ime="vrijednost"

### Pravila oblikovanja atributa



- Pravila imenovanja atributa ista kao za elemente
- Unutar istog elementa atributi moraju imati različita imena
- Vrijednost atributa mora biti navedena unutar navodnika (jednostrukih ili dvostrukih)
- Sadržaj atributa može se sastojati samo od teksta
- Sadržaj atributa se obrađuje od strane parsera
- Razmak između riječi u sadržaju može se tretirati kao odjeljivanje dviju vrijednosti u nizu vrijednosti pojedinog atributa

<flag colors="red white blue"/>

#### Kada elementi, a kada atributi?

#### Sadržaj elementa

 strukturirani podaci, jednostavno proširenje ili dodavanje višestrukih vrijednosti, jednostavniji za obradu

#### Atribut pridijeljen elementu

podatak o elementu (meta podatak), primjer:

#### • Preporuke:

- kad god je moguće, za zapis podataka koristiti elemente
- atribute koristiti za meta podatke i za definiranje logičke strukture podataka

#### Naredbe obrade



```
<?ime naredbe lista atributa ?>
```

- eng. processing instruction
- Naredbe aplikacijama za obradu xml dokumenata
- Ime i atributi ovisni kojoj aplikaciji je naredba namijenjena
- Ako aplikacija ne razumije naredbu, ignorira je
- Primjer:
  - naredba za primjenu stylesheeta za formatiranje xml dokumenta
  - <?xml-stylesheet type="text/css" href="table.css" ?>

#### Komentari



```
<!-- ovo je jedan redak komentara -->
<!-- komentar se proteže preko više redaka
...
-->
```

- Oznaka početka komentara <!--</li>
- Oznaka kraja komentara -->
- Sadržaj omeđen početnom i krajnjom oznakom komentara je ignoriran od strane parsera
- Nema gniježđenja komentara
  - prva detekcija --> od strane parsera terminira komentar

#### CDATA blokovi



- Parser ignorira CDATA blokove
  - nema prepoznavanja elemenata, ekspanzije entiteta ...
- Označavanje blokova koji sadrže veći broj nedozvoljenih znakova
  - npr. dijelovi programskog kôda, formule ...
- Podaci unutar bloka ne smiju sadržavati slijed znakova ]]>

#### Entiteti



- Entitet:
  - dio XML dokumenta
- XML dokument sastoji se od jednog ili više entiteta
- Vrste entiteta:
  - parsirani: datoteka s xml sadržajem
  - neparsirani: binarna datoteka
- Ugrađeni i naknadno definirani entiteti
- Unutarnji i vanjski entiteti
  - unutarnji: definirani unutar tipa dokumenta
  - vanjski: zaseban resurs, mora se prilikom parsiranja dohvatiti (slično #include direktivama u C/C++)

### Referenciranje entiteta



 Referenciranje entiteta unutar dokumenta:

```
&ime_entiteta;
```

- Referenca se u postupku parsiranja zamjenjuje sa sadržajem entiteta
  - dobiva se parsirani dokument
- Dodavanje znakova u dokument,
  - npr. Unicode znak π: π
- Korištenje naknadno definiranog entiteta π entitet mora biti definiran u sklopu definicije tipa dokumenta

```
Ugrađeni entiteti

< lt
> gt
& amp
' apos
" quot
```

### Bijeli znak (Whitespace)



- Različitost terminiranja retka teksta:
  - DOS & Windows: CR/LF, UNIX: LF, Mac: CR
- Preporučeno korištenje LF za terminiranje retka
- Kao bijeli znakovi tretiraju se skupno:
  - razmak (' '), tab ('\t'), CR(ASCII 13, '\r'), LF (ASCII 10, '\n')
- Dvije vrste bijelih znakova:
  - važan: dio sadržaja dokumenta, mora biti sačuvan nakon parsiranja
  - nevažan: primjena u formatiranju dokumenta, ne mora biti sačuvan nakon parsiranja
- Svi bijeli znakovi se, u općem slučaju, čuvaju tijekom parsiranja dokumenta

#### Ekvivalentnost XML dokumenata

#### Logička ekvivalentnost:

jednak sadržaj dokumenata

```
<student><jmbag>003643443</jmbag><ime>Marko</ime>
  <prezime>Ferković - Enter</prezime></student>
  <ime>Marko</ime>
  <prezime>Ferković - Enter</prezime>
  <prezime>Ferković - Enter</prezime>
  <jmbag>003643443</jmbag>
</student>
```

#### • Fizička ekvivalentnost:

- datoteke jednake na razini okteta (npr. korištenje alata diff ne pokazuje razlike između datoteka)
- svođenje na kanonički oblik (struktura, poredak atributa, kodiranje ...) za usporedbu fizičke ekvivalentnosti

#### XML deklaracija



<?xml version="1.0" encoding="UTF-8" standalone="yes" ?>

- Navođenje deklaracije na početku XML dokumenta
  - preporučeno (ali nije nužno)
- Znak < mora biti prvi znak unutar teksta</li>
- Atribut version mora biti naveden kao prvi atribut,
  - vrijednost mora biti "1.0"
- Atribut encoding je neobavezan, vrijednost mora sadržavati oznaku kodiranja dokumenta
  - ISO-\*, Unicode, UTF, ...
- Atribut standalone je neobavezan, označava ovisnost dokumenta o vanjskim entitetima

#### Struktura XML dokumenta



```
<?xml version="1.0" ...?>
                                      prolog
<?processing instr a ?>
<!-- komentar -->
<element>
                                       korijenski element
<!-- komentar -->
                                       ostatak
```

- XML dokument sastoji se od tri osnovna dijela:
  - prologa (neobavezan)
  - korijenskog elementa (obavezan)
  - ostatka dokumenta (neobavezan)

### Prolog i ostatak dokumenta



- Prolog dokumenta:
  - xml deklaracija
  - deklaracija tipa dokumenta
  - komentari
  - naredbe obrade
  - whitespace

- Ostatak dokumenta:
  - naredbe obrade
  - komentari
  - whitespace

#### Korijenski element



- Mora postojati isključivo jedan osnovni, korijenski element dokumenta
- Sadržaj dokumenta je unutar korijenskog elementa, u obliku elemenata, atributa, teksta itd.
- Unutar korijenskog elementa moguće navođenje
  - komentara, procesnih naredbi, whitespace, CDATA blokova, entiteta itd.

## nt

#### Dobro oblikovani XML dokument

- Dobro oblikovani (eng. well-formed) XML dokument zadovoljava sva prethodno navedena pravila strukture dokumenta, imenovanja elemenata i atributa, gnježđenja elemenata ...
- Parseri odbijaju obradu loše oblikovanih XML dokumenata

## Primjer dobre oblikovanosti



Primjer dobro oblikovanog XML dokumenta:
 <ž/>

Kolika je dužina ovog dokumenta u oktetima?

```
Ovisi;) 
ASCII: ne ide!
ISO-8859-1 ne ide!
ISO-8859-2: 4 okteta 3C BE 2F 3E
UTF-8: 8 okteta EF BB BF 3C C5 BE 2F 3E
UTF-16: 10 okteta FF FE 3C 00 7E 01 2F 00 3E 00
```

Koji je kod za znak ž u Unicode? 0x017E

## Primjene XML-a

#### Alati za pregled i uređivanje XML dokumenata

#### • Prikaz XML dokumenata:

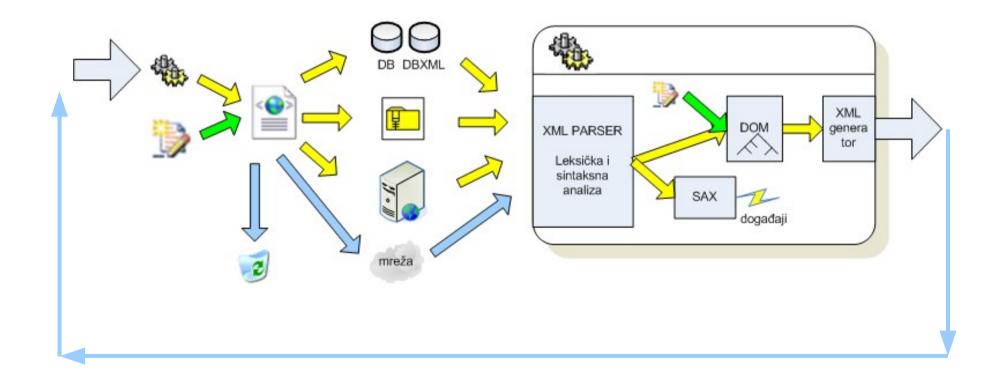
- bilo koji uređivač teksta opće namjene samo sadržaj
- Netscape/Firefox, IntenetExplorer, Opera sadržaj i struktura dokumenta, verifikacija, formatiranje, transformacije

#### Alati za uređivanje:

- uređivači teksta opće namjene (npr. notepad, vi, joe)
- prilagođeni uređivači (npr. XMLNotepad)
- složeni alati za razvoj (npr. XMLSpy)

## "Vrtlog života" XML dokumenta





#### Pohrana podataka



#### • Skalabilnost:

- jednostavne datoteke (npr. konfiguracijske datoteke aplikacije, ant build datoteke)
- pohrana složenih dokumenata, korištenih isključivo od strane aplikacija (npr. ova prezentacija)
- XML datoteke stvarane od
  - čovjeka (u pravilu jednostavne)
  - aplikacija (od jednostavnih do vrlo složenih)
- XML datoteke korištene gotovo isključivo od aplikacija

## Životni vijek XML dokumenata



- XML dokumenti po duljini životnog vijeka:
  - privremeni dokumenti (eng. transient)
  - trajni dokumenti (eng. persistent)
- Privremeni dokumenti se ne arhiviraju
  - ostaju u radnoj memoriji ili putuju mrežom u obliku poruka) ili se privremeno zapisuju u datotečnom sustavu tek radi razmjene s drugim aplikacijama
- Trajni dokumenti arhiviraju se u datotečnom sustavu ili u bazi podataka
  - mogu biti dostupni i putem mreže (web, ...)

### Arhiviranje XML dokumenata

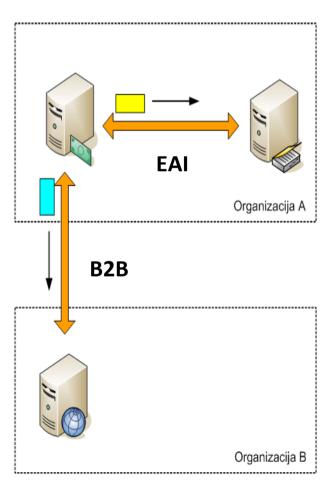


- Izvorne XML datoteke su tekstualne datoteke
  - mogu se koristiti alati za održavanje verzija (npr. subversion)
- XML datoteke mogu biti sažete
  - više srodnih datoteka može biti sažeto unutar iste arhive (npr. ova prezentacija: XML.odp)
  - Vrlo visok stupanj sažimanja XML datoteka
- Baze podataka:
  - nativeXML hijerarhijske baze podataka
  - relacijske baze podataka s mapiranjem
     XML ↔ relacijski model
- Pretraživanje dokumenata i baza dokumenata

## Integracija heterogenih aplikacija

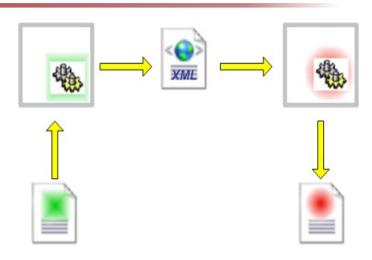


- Različite aplikacije unutar organizacije moraju razmjenjivati podatke (npr. skladište i financije)
  - EAI (Enterprise Application Integration)
- Različiti sustavi različitih organizacija moraju razmjenjivati podatke, npr.:
  - e-narudžbe, e-plaćanje, e-PDV
  - B2B, B2G
- Asinkrona komunikacija mrežom slanjem poruka u obliku privremenih XML dokumenata

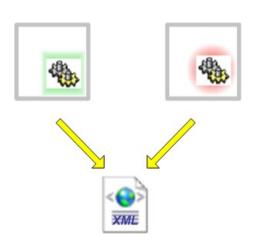


#### Prenosiva reprezentacija podataka

- Standardizirani format dokumenta neovisan o aplikaciji, jeziku, platformi, načinu prijenosa i/ili arhiviranja
- Omogućuje razmjenu dokumenata između aplikacija kao međuformat
- Omogućuje suradnju aplikacija na istom dokumentu ili parcijalno uređivanje dijelova dokumenta



razmjena dokumenata



suradnja na istom dokumentu

#### Objavljivanje i prikaz dokumenta



- XML odvaja podatke i njihov prikaz
- Različiti prikazi XML dokumenta:
  - po korisniku
  - po uređaju
  - po mediju



- XML dokumenta
  - transformacija nakon prijenosa na uređaj koji služi za prikaz sadržaja
- dokumenta spremnog za prikaz
  - transformacija prije objave dokumenta ili prilikom dohvata (npr. transformacija XML → HTML+CSS)









#### Učitavanje XML dokumenta u aplikaciju

- Parsiranje dokumenta
  - provjera dobre oblikovanosti dokumenta (obvezno)
  - provjera valjanosti dokumenta
    - validirajući parseri
  - dokument mora zadovoljiti prvu ili obje provjere
  - dvije vrste parsiranja:
    - linijsko
    - potpuno
- Stvaranje unutarnje reprezentacije dokumenta
  - linijsko parsiranje (SAX) ne stvara reprezentaciju
  - potpuno parsiranje (DOM) objektni model dokumenta

#### Uređivanje dokumenta XML iz aplikacije

#### Objektni model:

- uređivanje sadržaja i strukture
- stvaranje modela novog dokumenta
- izvoz modela u formatu XML (datoteka, tok, ...)

#### Bez modela

- stvaranje XML datoteke ispisivanjem teksta u datoteku korak po korak, npr.:
  - korištenjem funkcije fprintf()

# Prostori imena

#### Problem konflikta imena elemenata

- Imena nastaju neovisno, npr.
  - eIndeks i potvrda o liječničkom pregledu
- Problem kod spajanja
  - sadržaji iz neovisnih izvora
    - za opis različitih koncepata mogu se koristiti elementi jednakih imena, a različite semantike, sadržaja, strukture ...
- Potrebno dodatno označiti
  - o kojem se točno konceptu (elementu) radi

#### Prostori imena



- Rješenje na razini sintakse:
  - korištenje prefiksa za razlikovanje različitih elemenata jednakog imena

```
<p:id/> \( \neq \q \text{:id/>} \)
```

- p:id i q:id su valjana imena elemenata, tretirana od strane parsera kao i ostala valjana imena elemenata
- Rješenje na logičkoj razini:
  - p i q su dva različita prostora imena (namespaces);
  - svi elementi s istim prefiksom pripadaju zasebnom prostoru imena (p:id pripada prostoru imena p)
- Prefiksi se definiraju za svaki dokument zasebno
  - globalna definicija prefiksa ne bi riješila problem!

#### Jedinstveni identifikator prostora imena

 URI kao globalno jedinstveni identifikator resursa, u ovom slučaju prostora imena

http://www.w3.org/TR/html4/

http://www.w3.org/1999/XSL/Transform

http://www.fer.hr/eindex/ver1.0

- temelji se na hijerarhijskoj podjeli odgovornosti imenovanja domena i upravljanju resursima npr. ICANN\*-CARNet-FER)
- stvaran resurs reprezentiran URI-jem ne mora postojati

<sup>\*</sup>Internet Corporation for Assigned Names and Numbers

#### Deklariranje prostora imena



 Povezivanje prefiksa (lokalna informacija) i URI-ja (globalna informacija) atributom xmlns:

- Doseg prostora imena je element njegove deklaracije uključujući sadržaj
  - u primjeru, doseg ex je element eindex
- Podrazumijevani (eng. default) prostor imena:

```
xmlns="namespaceURI"
<eindex xmlns="http://www.fer.hr/eindex/ver1.0">
...
</eindex>
```



#### Primjer korištenja prostora imena

```
<ex:eindex xmlns:ex="http://www.fer.hr/eindex/ver1.0" ex:version='1.0'>
    <ex:student>
       <ex:studentID>0036435453</ex:id>
       <ex:firstName>Marko</ex:firstName> ...
    </ex:student>
    <ex:courses>
       <ex:course>
               <ex:title>OpenComputing</ex:title> ...
       <ex:exam>
               <ex:date>2008-07-04</ex:date>
               <ex:grade>C</ex:grade> ...
    <ex:attachments>
       <med:UMed xmlns:med="http://www.hzzo-net.hr/hrmedSchema/2008-01>
               <med:exam>
                       <med:id>A65ZGB00456345F</med:id>
                       <med:date>
                              <med:year>2008</med:year>
                              <med:month>02</med:month>
                              <med:day>17</med:day>
                       </med:date>
                       <med:status>45F</med:status> ...
       </med:UMed> ...
    </ex:attachments>
</ex:eindex>
```

#### Literatura

- http://www.w3.org/XML/
- http://www.w3schools.com/
- http://www.itwriting.com/xmlintro.php



## Pitanja?







```
Mozilla Firefox

File Edit View History Bookmarks Tools Help

Dactylorhiza maculata

Pinus

Mozilla Firefox

L X

Eile Edit View History Bookmarks Tools Help

Google

Google

Done
```

